UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS

Almacenes y Minería de Datos

Tarea 2: EDA, Personas Desaparecidas en México

Alumnos:

- Méndez Ávila Luis Geovanni 317143980
- Paredes Zamudio Luis Daniel 318159926
- Sánchez Rosas Roberto Samuel 318355159
- Domínguez Sánchez Gustavo Alonso 418047121

Profesora: L. en C.C. Jessica Santizo Galicia

23 de Marzo de 2026

1. Empresa y Metodología de Minería de Datos

1.1. Roberto Samuel Sánchez Rosas

Empresa elegida **Amazon**.

Amazon, como pionero en infraestructura en la nube y comercio electrónico, no utiliza metodologías estáticas tradicionales. Para el desarrollo de proyectos de Minería de Datos, Amazon implementa una evolución orientada a la producción llamada **AWS Machine Learning Lens**, la cual forma parte de su *Well-Architected Framework*.

Esta metodología estructura el ciclo de vida de los datos en seis fases iterativas altamente integradas con la ingeniería de software:

- **Identificación de objetivos comerciales:** Fieles a su filosofía de *Working Backwards*, el proceso comienza definiendo el valor de negocio y los criterios de éxito antes de explorar la información.
- **Planteamiento del problema:** Se traduce el objetivo comercial en un problema técnico de *Machine Learning*, definiendo la métrica a optimizar.
- **Procesamiento de datos:** Abarca la recolección, limpieza y transformación (*feature engineering*). Para manejar volúmenes masivos, se apoyan en *Data Lakes* y *Data Warehouses*.
- **Desarrollo del modelo:** Consiste en el entrenamiento, evaluación y ajuste de los algoritmos en entornos programables.
- **Despliegue:** El modelo validado se lleva a entornos de producción para generar predicciones o inferencias automatizadas.
- **Monitoreo y mantenimiento:** Se vigila el modelo en producción para detectar desviaciones en los datos (*data drift*) y automatizar ciclos de reentrenamiento.

Esta aproximación es conveniente ya que permite analizar no solo los datos de forma aislada, sino asegurar que los hallazgos se conviertan en soluciones escalables.

Amazon Web Services. (2025). Machine Learning Lens - AWS Well-Architected Framework. AWS Whitepapers & Guides. Recuperado de: https://docs.aws.amazon.com/wellarchitected/latest/machine-learning-lens/machine-learning-lens.html

Amazon Web Services. (2025). Well-Architected machine learning lifecycle. AWS Documentation. Recuperado de: https://docs.aws.amazon.com/wellarchitected/latest/machine-learning-lens/machine-learning.html

1.2. Luis Geovanni Méndez Ávila

Empresa elegida : **IBM**

IBM es una empresa que tiene mucha influencia en el desarrollo de metodologías de minería de datos. Es ampliamente reconocida por promover el estándar CRISP-DM.

Fases de CRISP-DM

- Comprensión del negocio
- Comprensión de los datos
- Preparación de los datos
- Modelado
- Evaluación
- Despliegue

CRISP-DM es una metodología iterativa que permite adaptar los modelos a los objetivos del negocio.

IBM desarrolló posteriormente ASUM-DM *(Analytics Solutions Unified Method for Data Mining)*, que extiende a CRISP-DM incorporando prácticas ágiles y despliegue continuo.

- Integración de metodologías ágiles
- Enfoque en implementación en producción
- Gestión del ciclo de vida del modelo

Fuente consultada:

- IBM. (2015). *Analytics Solutions Unified Method for Data Mining (ASUM-DM)*, recuperado de IBM.

1.3. Luis Daniel Paredes Zamudio

Empresa elegida : **Pinterest**

Pinterest emplea una metodología de minería de datos y aprendizaje automático altamente escalable, centrada en el procesamiento masivo de información estructurada y no estructurada para personalizar la experiencia de más de 460 millones de usuarios.

El núcleo de su metodología analítica se basa en el aprendizaje de representaciones *(Representation Learning)* y las Redes Neuronales de Grafos *(Graph Neural Networks)*. Dado que la naturaleza de Pinterest es altamente visual y relacional, los ingenieros de datos desarrollan modelos multimodales y algoritmos como *PinSage*, el cual incrusta usuarios, imágenes y tableros en un inmenso grafo de conocimiento. Esto les permite unificar representaciones semánticas que combinan texto, imágenes y comportamiento del usuario. Gracias a este enfoque, los proyectos de minería de datos de la compañía logran descubrir patrones ocultos de similitud visual y temática, lo que alimenta directamente sus motores de recomendación y clasificación de contenido de manera altamente precisa y contextualizada.

2. Descripción del Dataset Asignado

Para este análisis, estamos trabajando con el archivo denominado `tot_reg_desap.csv`, el cual contiene un registro masivo del Registro Nacional de Personas Desaparecidas y No Localizadas (RNPDNO) en México. Antes de aplicar cualquier técnica de limpieza o transformación, realizamos una inspección inicial de la estructura pura de los datos para su comprensioń.

El dataset original se compone de 89,720 filas y 13 columnas. Este volumen de información es lo suficientemente robusto como para extraer conclusiones con base estadística, pero también requiere técnica de preprocesamiento para manejar el ruido inherente a los registros masivos.

Las 13 columnas originales capturan una mezcla de información demográfica, geográfica y administrativa. Entre las más imprescindibles para nuestro análisis destacan:

- `nombrecompleto` nos da el registro nominal del individuo.
- `entidad_desap` indica el estado donde ocurrió el evento.
- `fecha_desap` contiene la fecha exacta en la que se reportó la desaparición (formato día/mes/año).
- `estatus_busqueda` es una variable categórica que nos indica en qué fase se encuentra el caso (ej. Çon indicios / Ubicada", "Se requiere reportante").
- Además, existen otras columnas de control interno de las bases de datos propias de la fuente como como rnpdno_json, `rnpdno_csv`, `bg_1`, `DC_id` que fungen como banderas (booleanos o llaves) sobre el origen y control del reporte en los distintos sistemas. Para fines de este analisis, estas variables son de menor importacia.

En este conjunto de datos, cada fila representa un registro o reporte de desaparición individual, no necesariamente a una persona física única e irrepetible. Debido a la naturaleza de la captura de datos en México, descubrimos en nuestro análisis inicial que existen homonimias o duplicados parciales (reportes actualiza-

dos o levantados en diferentes instancias para la misma persona). Por lo tanto, nuestra unidad de análisis estadística es el caso reportado.

El dataset alberga registros históricos que abarcan varias décadas, pero concentra su mayor densidad operativa en el periodo contemporáneo. Basándonos en la extracción de la variable `fecha_desap`. Esto nos otorga una panorama lo suficientemente actualizado de la crisis en los últimos tiempos, permitiéndonos contrastar históricamente cómo ha evolucionado el volumen de reportes hasta la actualidad.

3. Diccionario de Datos

Variable	Descripción	Tipo (Pandas)	Tipo (Semántico)	Tipo Estad.	No Nulos	Nulos	Únicos	Ejemplos
dataset_id	Identificador único del registro.	int64	entero	numérico	89720	0	89720	1, 2
nombrecompleto	Nombre completo de la persona reportada como desaparecida/no localizada.	str	texto	categórico	89720	0	88513	LUIS ADRIAN JUAREZ MORALES
rnpdno_json	Presencia/coincidencia en RNPDNO (0/1).	int64	entero	numérico	89720	0	2	1, 0
entidad_desap	Entidad donde se reporta la desaparición/no localización.	str	texto	categórico	89720	0	33	QUERETARO, CHIHUAHUA
pre_rnped	Indicador previo asociado a RNPED (0/1).	int64	entero	numérico	89720	0	2	0, 1
rnped	Presencia/coincidencia con registros RNPED (0/1).	int64	entero	numérico	89720	0	2	0, 1
rnpdno_csv	Presencia/coincidencia en RNPDNO en formato CSV (0/1).	int64	entero	numérico	89720	0	2	1, 0
bg_1	Bandera/indicador auxiliar de consistencia (primer indicador).	int64	entero	numérico	89720	0	2	0, 1
estatus_busqueda	Estatus del proceso de búsqueda.	str	texto	categórico	62356	27364	9	Con indicios / Ubicada
bg_2	Bandera/indicador auxiliar de consistencia (segundo indicador).	int64	entero	numérico	89720	0	2	0, 1
fub	Folio Único de Búsqueda.	str	texto	categórico	63670	26050	63089	187731B1B-3302-4BE3
DC_id	Identificador de cruce entre fuentes (JSON/CSV/-FUB).	str	texto	categórico	80069	9651	79657	101 (json), 5673 (csv)
fecha_desap	Fecha de desaparición o no localización reportada.	str	fecha	categórico	82795	6925	7749	19/04/2023, 12/07/2016

Tabla 1: Diccionario de Datos

4. Aplicación de CRISP-DM

4.1. Business Understanding

El objetivo principal radica en analizar los registros de personas desaparecidas para identificar patrones relevantes temporales, espaciales y operativos que permitan una mejor comprensión del fenómeno a nivel nacional. Para lograrlo, se formularon las siguientes preguntas de análisis, cada una orientada a resolver una problemática específica:

- ¿Cuáles son las entidades con mayor incidencia de desapariciones?

  Permite mapear la concentración del problema para priorizar y direccionar los esfuerzos de búsqueda y recursos gubernamentales hacia las zonas críticas.

- ¿Cuál es la tendencia de desapariciones a lo largo del tiempo (aumento o disminución)?

  Es vital para evaluar el comportamiento histórico del fenómeno y medir el posible impacto a largo plazo de las políticas de seguridad pública.

- ¿Qué proporción de casos está activo vs. resuelto?

  Proporciona un indicador macro del nivel de rezago institucional a nivel federal frente a la crisis.

- ¿Cuál es la tasa de resolución por entidad?

  Ayuda a identificar qué fiscalías estatales son más efectivas en la localización de personas, revelando posibles disparidades operativas o de infraestructura en el país.

El proyecto se considerará exitoso si logra:

- Identificar de forma clara las tendencias temporales y globales del dataset
- Detectar y delimitar geográficamente las zonas críticas de atención
- Generar resultados e interpretaciones de alta utilidad para la toma de decisiones, logrando mitigar las inconsistencias inherentes de los datos de origen

4.2. Data Understanding

Se realiza una exploración inicial del dataset para evaluar su calidad y la distribución estadística de las variables clave (como entidades y estatus). En esta fase se plantean hipótesis preliminares sobre la existencia de un subregistro sistemático en las fechas de desaparición y posibles discrepancias u omisiones generadas durante la unificación de los registros nacionales previos (RNPED: Red Nacional de Personas Desaparecidas) y actuales (RNPDNO: Red Nacional de Personas Desaparecidas No Localizadas).

4.3. Data Preparation

Similar al proceso de Data Staging en un Almacén de Datos, esta fase contempla la limpieza, estandarización y transformación del dataset crudo. Las tareas específicas incluyen la normalización de variables nominales a formato snake_case y la conversión estricta de cadenas de texto a tipos de dato `datetime`.

Para este caso crearemos un dataset reducido en base a las variables que se mostrarán a continuación. Esto permitirá resolver interrogantes derivadas de las problemáticas previamente definidas:

- `nombrecompleto`: Es indispensable conocer el nombre de la persona a identificar para tener un registro unificado para cada quien.

- `entidad_desap`: ¿Cuál es la media y mediana de desaparecidos en cada entidad?, ¿Cuál entidad es la que más desaparecidos tiene?
- `fecha_desap`: ¿Cuál es la media y mediana de desapariciones por año?, ¿Cuál es el año con más desapariciones?
- `estatus_busqueda`: ¿Cuál es el estatus más común de las búsquedas? ¿Cuantos casos están resueltos? ¿Cuantos casos están inconclusos?

Luego, como las fechas en el dataset no aparecen como un tipo número (o mejor dicho, de tipo *fecha*), se deben aplicar una transformación a un tipo de dato `datetime` que nos permita manipular las fechas por dia, mes y año. Además, usaremos como variable derivada `año_desap` para analizar tendencias de desapariciones por año más adelante.

En cuanto a la limpieza inicial se refiere, se deben tratar los campos nulos y entradas duplicadas. Una impresión general del conjunto datos hace que notar que existen casos en los que existen datos nulos y/o faltantes nombre del la persona y/o fecha de desaparición. Nuestro acercamiento a estos valores será el siguiente.

1. Entradas con todos los campos iguales se deben eliminar pues estamos hablando de entradas repetidas para la misma persona.
2. Entradas con algún campo diferente deben tratarse como casos distintos.

4.3.1. Resultados de la Limpieza y Consideraciones Iniciales

Este procesamiento anterior genera los siguientes resultados:

```
                nombrecompleto              entidad_desap  \
0              LUIS ADRIAN JUAREZ MORALES     QUERETARO
1      ERNESTO ALONSO HERNANDEZ GUTIERREZ     QUERETARO
2            PIEDAD JESUS GUERRERO CHAVEZ     QUERETARO
3                        LORENZO MARTINEZ     QUERETARO
4                   AGUSTINA OLVERA OCHOA     QUERETARO
...                                   ...           ...
89715                   ABEL DIYARZA MEZA      TLAXCALA
89716             PERLA SANCHEZ VELAZQUEZ      TLAXCALA
89717           ARACELI SIMBRON HERNANDEZ      TLAXCALA
89718                 KARLA ROMERO TEZMOL      TLAXCALA
89719            ALEJANDRO REYES MARTINEZ      TLAXCALA
```

```
                      estatus_busqueda fecha_desap  anio_desap
0                                  NaN  2023-04-19      2023.0
1               Con indicios / Ubicada  2016-07-12      2016.0
2                  Se busca reportante  2017-09-26      2017.0
3      Se requieren datos de identidad  2010-03-17      2010.0
4                                  NaN  2023-06-04      2023.0
...                                ...         ...         ...
89715           Con indicios / Ubicada  2014-09-02      2014.0
89716                              NaN  2017-01-15      2017.0
89717                              NaN  2013-09-19      2013.0
89718           Con indicios / Ubicada  2016-01-13      2016.0
89719  Se requieren datos de identidad  2011-12-26      2011.0

[89132 rows x 5 columns]

 Revisamos limpieza de duplicados correcta mostrando el dataframe de 'duplicados' vacío:

Empty DataFrame
Columns: [nombrecompleto, entidad_desap, estatus_busqueda, fecha_desap, anio_desap]
Index: []
```

Tras el procesamiento se identificaron 588 registros duplicados y posteriormente, tras la limpieza, esto se redujo a un dataframe vacio, lo que nos indica que se eliminaron estas entradas correctamente.

Sin embargo, dada la naturaleza de los datos, eso no significa que se hayan eliminado entradas en donde se este hablando de personas homónimas o con registros con información parcialmente coincidente. Por ejemplo, está la siguiente entrada en el dataframe reducido:

4.3.2. Medidas de Localización

La media de desapariciones por entidad es de aprox. 2700 personas. Esto implica que si las desapariciones estuvieran distribuidas de manera uniforme, cada estado tendría esa cantidad de casos. La realidad es distinta pero no menos triste: existen estados muy por encima de la media y otros muy por debajo.

El principal dato destacable de estos valores, por entidad, es que la moda indica que Tamaulipas es el estado con mayor número de desapariciones registradas.

Un análisis adicional interesante sería relacionar la cantidad de desapariciones con la población de cada

entidad, lo que permitiría obtener una visión más precisa sobre la situación de inseguridad.

La media de desapariciones por año es de aprox. 1417 personas. Esto indica que, bajo una distribución uniforme, cada año tendría esa cantidad de casos. No obstante, hay años con muy baja concentración de desapariciones y otros que concentran una gran proporción del total.

Otros datos destacables por año son los siguientes:

La mediana del año 2016 indica que el 50 % de las desapariciones ocurrieron antes de ese año y el otro 50 % después. Es decir, 50 % entre 1964 y 2016 y la otra mitad hacia el 2023. Esto representa un dato preocupante, ya que sugiere un incremento significativo de las desapariciones en años recientes.

La moda recae totalmente en el año 2007, es el año con mayor número de desapariciones registradas. Otro dato que sale a raíz de estos cálculos es que la moda del estado de búsqueda más común es "se busca reportante". Este dato es igual de alarmante que los anteriores. Los reportes de desaparición que se encuentran en este estado tienen la particularidad de que no sabe incluso quien reportó a la persona desaparecida.

4.3.3. Medidas de Variabilidad

media	**varianza**	**desv_std**	**min**	**q1**	**mediana**	**q3**	**max**	**rango**	**IQR**	**CV**
2014.516681	43.036292	6.560205	1964.0	2011.0	2016.0	2019.0	2023.0	59.0	8.0	0.003256

Tabla 2: Estadísticas Descriptivas - Año de Desaparición

Estos datos nos hacen concluir que al menos el 50 % de los casos de desapariciones se concentran entre los 2010 y 2020. Como se había concluido previamente, la mediana de los casos de desaparición se encuentra alrededor del año 2016.

4.3.4. Medidas de Heterogeneidad

Variable	**Métrica**	**Valor**
entidad_desap	Shannon	3.021391
estatus_busqueda	Shannon	1.323578
anio_desap	Gini	0.001617

Tabla 3: Métricas de Heterogeneidad y Distribución

Variable	Nivel de Heterogeneidad	Interpretación
entidad_desap	Alta	La desaparición de personas es un fenómeno distribuido geográficamente.
estatus_busqueda	Media - baja	Concentración en pocos tipos de estatus. Esto significa que la mayoria de casos cae en pocas categorías.
anio_desap	Muy baja	La cantidad de desaparecidos se distribuye de manera uniforme a lo largo del tiempo.

Tabla 4: Análisis de Heterogeneidad e Interpretación

4.3.5. Correlación

La correlación está diseñada para medir la relación entre variables numéricas continuas. Sin embargo, nuestro conjunto de datos está compuesto principalmente por variables categóricas, como `entidad_desap` o `estatus_busqueda`. No es posible aplicar una fórmula matemática de correlación directamente sobre nombres de estados.

Para descubrir patrones útiles en este dataset, realizamos una transformación de los datos y construiremos una tabla cruzada agrupando los datos para contar la frecuencia de desapariciones por año para cada entidad. Esto nos permitirá conocer si el aumento o disminución de desapariciones en un estado ocurre de manera simultánea en otro.

Se implementó de esta manera.

- **Top de entidades**: Seleccionamos las 20 entidades con mayor número de casos históricos (excluyendo `SE DESCONOCE`) para enfocarnos en las entidades reales.
- **Pearson**: Utilizamos la correlación de Pearson para identificar relaciones lineales directas a lo largo de los años.
- **Heatmap**: Empleamos un mapa de calor para traducir la matriz de 20x20 en una escala de colores. Los tonos rojos cálidos representan correlaciones positivas fuertes (cercanas a 1), los tonos azules representan correlaciones negativas (cercanas a -1) y los colores pálidos indican una ausencia de relación (cerca de 0).

Estos datos nos permiten realizar las siguientes hipótesis:

- Estados con comportamientos idénticos sugiere la existencia de zonas inseguras que afectan a regiones completas de manera conjunta.
- Estado de México y Sinaloa con $r = 0.96$, Chihuahua y Sinaloa con $r = 0.95$ y Guanajuato y Sonora con $r = 0.92$ son los estados con correlaciones más altas, lo que indica que los números de desapariciones

en estos estados suben y bajan al mismo tiempo.

- Por su lado, Chiapas y Tamaulipas con $r = 0.03$, Puebla y Veracruz con $r = 0.04$ y Chiapas y Coahuila con $r = 0.05$ son los estados en donde menos se da el fenómeno anterior.

- La existencia de unicamente correlaciones positivas indica que las desapariciones generalmente van en aumento en todas las entidades.

4.3.6. Limpieza Final de datos

Al inicio de este archivo se realizo una limpieza preliminar de los datos para poder manipularlos. Recordemos uno de los criterios que se utilizaron en su momento fue quedarnos unicamente con las columnas nombre-completo, entidad_desap, fecha_desap, y estatus_busqueda para poder trabajar con valores que nos ayudaran a contestar las preguntas planteadas al inicio.

Estos ajustes, sumados a los resultados anteriores, nos lleva a las siguientes conclusiones sobre el estado original de los datos:

Trístemente, las columnas estatus_busqueda y fecha_desap son la que más valores nulos contienen. Esto coincide con la averiguación inicial de que este dataset es una mezcla de datasets previos. Finalmente, la exportación del dataset modificado como archivo .csv se hace la siguiente manera:

4.4. Modeling

Aunque el alcance de este proyecto no requiere el entrenamiento de modelos predictivos o de aprendizaje automático, las técnicas de minería de datos idóneas para este escenario incluyen el Agrupamiento (Clustering) para la identificación de zonas de alta densidad de incidencia, y algoritmos de Reglas de Asociación para descubrir relaciones probabilísticas entre el perfil de la desaparición y el estatus de búsqueda asignado.

4.5. Evaluation

Los hallazgos se validarán contrastando los resultados estadísticos con el contexto nacional y la documentación de las fuentes oficiales. Una limitación crítica identificada es la variabilidad en la calidad de captura entre las distintas fiscalías, lo que introduce un sesgo institucional. El criterio de utilidad radicará en qué tan accionables son los patrones descubiertos para optimizar la toma de decisiones.

4.6. Deployment

La entrega final y socialización de los resultados se realizará mediante una presentación ejecutiva desarrollada con Quarto. Esta herramienta permitirá integrar de forma nativa el entorno de ejecución de Python con la narrativa de los datos, garantizando la reproducibilidad de las gráficas y medidas calculadas. La presentación

estará diseñada con un lenguaje claro, omitiendo tecnicismos de código, para orientar los hallazgos hacia la toma de decisiones a nivel directivo. Adicionalmente, el código fuente en formato .qmd (Quarto) y el dataset limpio quedarán versionados en el repositorio de Git para asegurar la trazabilidad del proyecto.

5. Hallazgos Principales

- El análisis de frecuencias y las medidas de localización demuestran que el fenómeno de las desapariciones no es homogéneo a nivel nacional, sino que sufre de una concentración extrema. Mientras que la media nacional de desapariciones por entidad es de aproximadamente 2,700 casos, estados como Tamaulipas (11,786) y el Estado de México (10,935) superan este promedio.

- El año 2007 tiene el mayor pico histórico. Al calcular la moda histórica es el año 2007, con un registro anómalo de 10,410 desapariciones. Estadísticamente, este pico representa un valor atípico (outlier) masivo en comparación con años previos, sin embargo no hay que perder de vista que hay posibilidad de que pueda tratarse de un periodo histórico con mucha inseguridad.

- Aceleración reciente en las desapariciones. Aunque el año 2007 tiene la mayor cantidad absoluta de casos, la mediana de los años del dataset se sitúa en 2016. Dado que los registros abarcan desde 1967 hasta 2023, el hecho de que el percentil 50 caiga en el año 2016 nos dice que el 50 % de todas las desapariciones históricas documentadas en este dataset han ocurrido en tan solo los últimos 7 años analizados (2016-2023).

- Un hallazgo fundamental derivado de la fase de Data Preparation es la enorme cantidad de valores perdidos. La columna `estatus_busqueda presenta` 27,364 valores nulos. En nuestro análisis se suguiere que estos no son faltantes aleatorios (MCAR), sino que podrían comportarse como MNAR (Missing Not At Random): la ausencia de estatus ocurre probablemente por falta de recursos o capacidad para clasificar o dar seguimiento a estos reportes de desaparición.

- Gracias a la transformación de las categorías para medidas de correlación. mediante un heatmap, logramos identificar comportamientos por zonas entre entidades colindantes. Se descubrieron correlaciones fuertes positivas en zonas geográficos específicos, destacando el Noreste (Nuevo León y Tamaulipas con $r = 0.87$) y el Pacífico (Colima y Nayarit con $r = 0.87$). Esto nos permite concluir que las oleadas de desapariciones en estas regiones ocurren simultáneamente.

- El análisis de la variable categórica `estatus_busqueda` nos dice que la categoría de personas Çon indicios / Ubicada"suma apenas 12,563 registros. En contraste, las categorías que indican casos como "Se busca reportante"(22,704 casos) y "Se requieren datos de identidad"(18,362 casos) dominan la distribución. Este hallazgo demuestra que, en la gran mayoría de los casos, el sistema es incapaz de avanzar con la investigación por falta de datos básicos o abandono de las carpetas.

- No existen tantos casos de homónimos en el dataset a pesar de su tamaño. Esto sale a relucir debido a variabilidad de datos entre registros con el mismo nombre (cuando aplica). Esto, contradictoriamente al resto de casos duplicados, hace todo lo contrario, permite encontrar registros de personas únicas que en primera instancia no se hubieran detectado de no ser por la identificación de estas características.

- A pesar del indicador de Tabasco, Edo. Mex. y Sinaloa tienen la mayor correlación en cantidad de desaparecidos a lo largo del tiempo. Esto podría significar una conexión no grata entre ambos estados, como lo podría ser alguna operación ilegal de fondo que afecte a ambas entidades.

6. Conclusión

La aplicación de la metodología CRISP-DM y las técnicas de Análisis Exploratorio de Datos (EDA) sobre nuestro dataset de personas desaparecidas en México nos ha permitido ver más allá de la simple visualización de conteos a una interpretación con naturaleza estadística de una de las crisis sociales más graves del México contemporáneo.

El fenómeno de las desapariciones presenta una distribución matemática altamente asimétrica, tanto en el tiempo como en el espacio. Las medidas de localización demuestran que la crisis afecta al país de manera equitativa. Existe una variabilidad extrema donde unas cuantas entidades actúan como zonas de concentración alta de casos.

Referencias

[1] AI Magazine. *How data engineering is powering Pinterest's global platform*. https://aimagazine.com/videos/how-data-engineering-is-powering-pinterests-global-platfor. Accedido: 2026-03-27.

[2] DEV Community. *How does Pinterest use machine learning (ML)?* https://dev.to/mage_ai/how-does-pinterest-use-machine-learning-ml-3eb2. Accedido: 2026-03-27.

[3] Harvard Digital Initiative. *How Pinterest uses machine learning to provide tailored recommendations to million of users worldwide*. https://d3.harvard.edu/platform-digit/submission/how-pinterest-uses-machine-learning-to-provide-tailored-recommendations-to-million-of-users-worldwide/. Accedido: 2026-03-27.

[4] Pinterest. *Pinterest Labs*. https://labs.pinterest.com/. Accedido: 2026-03-27.

[5] SlideShare. *Pinterest - Big Data Machine Learning Platform at Pinterest*. https://www.slideshare.net/slideshow/pinterest-big-data-machine-learning-platform-at-pinterest/151167538. Accedido: 2026-03-27.